

CompStat Rio

Guia de Leitura da Aplicação

Inteligência territorial para segurança pública municipal

Arthur Vasconcellos, Pedro Forlevezi, Pedro Ribbe e Pedro Rezende

28 de maio de 2026

Documento didático destinado à alta gestão pública. Apresenta o que a aplicação CompStat Rio entrega, como navegar nela, e a especificação econométrica por trás do mapa preditivo de risco.

Decisão final humana. A plataforma produz rascunho auditável; a equipe valida antes de qualquer ação.

Sumário

1	Introdução	2
2	Como navegar	3
3	Panorama Operacional: o Relatório Analítico de Área	3
3.1	S1 — Identificação	3
3.2	S2 — Mapa de Hotspots	4
3.3	S3 — Resumo Executivo	5
3.4	S4 — Ocorrências no Período	6
3.5	S5 — Análise Temporal	7
3.6	S6 — Dinâmica Criminal	7
3.7	S7 — Emprego do Efetivo da FM	8
3.8	S8 — Fatores Urbanos	8
3.9	S9 — Câmeras	9
3.10	S10 — Coincidências de Alto Risco e Plano de Ação	9
4	Mapa Preditivo	12
4.1	O que é e como ler	12
4.2	Especificação econométrica	12
4.3	Como interpretar o modelo	13
4.4	Métricas de validação	15
4.5	Drivers por área	16
4.6	Painel de variáveis acionáveis	17
4.7	Mapa interativo e popups por hexágono	18
4.8	Coeficientes em português	20
5	Guardrails de IA responsável	22

1 Introdução

O **CompStat Rio** é a plataforma de inteligência territorial da Prefeitura do Rio de Janeiro voltada para segurança pública municipal. O modelo de gestão CompStat realiza reuniões periódicas em que o Prefeito e a alta gestão decidem, com base em dados, onde a Força Municipal (FM) deve atuar e quais fatores urbanos devem ser resolvidos pelos órgãos responsáveis (Comlurb, RioLuz, Seconserva, CET-Rio, SEOP, SMAS, SMTR, GM-Rio).

O problema dos silos. As fontes de dados — ocorrências georreferenciadas, denúncias do Disque Denúncia, relatórios de inteligência (RELINTs), fatores urbanos mapeados em campo e câmeras — vivem em sistemas isolados. Cruzar manualmente esses silos para produzir um Relatório Analítico de Área consome horas que poderiam ser dedicadas à análise. O CompStat Rio automatiza esse cruzamento.

Três camadas, uma plataforma. A inteligência central sobrepõe, no mesmo ponto do mapa, três camadas:

- **Mancha criminal** — onde o crime acontece, na forma de ocorrências de roubo e furto georreferenciadas.
- **Fator urbano** — qual condição ambiental facilita o crime (iluminação deficiente, calçada obstruída, vegetação cobrindo postes, mobiliário abandonado, etc.). É a alavanca da intervenção municipal.
- **Dinâmica criminal** — como o crime acontece (modus operandi, rotas de fuga, perfis de vítima), inferida do texto livre de RELINTs e Disque Denúncia.

O papel da IA. A inteligência artificial amplifica a análise — sintetiza texto, cruza dados e propõe rascunhos — mas *nunca substitui o gestor*. Os guardrails da plataforma são detalhados na seção 5.




Figura 1: Página inicial do CompStat Rio: lista de áreas da Força Municipal ordenadas por urgência (volume de ocorrências de roubo e furto no período do piloto). Selecionar uma área abre o relatório analítico completo.

2 Como navegar

A aplicação tem duas visões principais, alternadas por um seletor de abas centralizado no topo:

- **Panorama Operacional** — a entrada padrão: lista de áreas prioritárias e, dentro de cada uma, o relatório analítico completo.
- **Mapa Preditivo** — a previsão econométrica de risco para as próximas 1, 2 e 4 semanas (seção 4). *Essa é a maior inovação do nosso produto, e a que temos mais esperança de que gere impacto real na produtividade de gestores públicos.*



Figura 2: Seletor de abas no topo. As duas visões têm igual destaque visual; a aba ativa fica em azul-petróleo.

A lista de áreas (figura 1) é ordenada por ranking de volume de ocorrências. Ao clicar em uma área, o usuário entra no **Relatório Analítico de Área**, que segue o formato dos Relatórios de Inteligência (RELINTs) já adotados pela FM. Cada relatório é estruturado em 10 seções (S1 a S10), descritas a seguir.

3 Panorama Operacional: o Relatório Analítico de Área

3.1 S1 — Identificação

Cabeçalho da área: nome, polígono oficial da FM, bairros principais, domínios territoriais de organizações criminosas identificados, AISP e contagem de trechos críticos detectados pelo motor

de cruzamento.

01 IDENTIFICAÇÃO DA ÁREA

Dados administrativos e território

Editar

Perguntar ao copiloto

ÁREA DA FM

20 — Presidente Vargas - Campo de Santana - Central do Brasil - Cinelândia

BAIRROS

AISP

a preencher

DELEGACIA (DP)

a preencher

BATALHÃO (BPM)

a preencher

BASE DA FM

a preencher

SUBPREFEITURA

a preencher

GRUPO CRIMINOSO DE INFLUÊNCIA

TRECHOS CRÍTICOS

12

DIAGNÓSTICO IA

... Confiança alta

Figura 3: Seção 1 — Identificação da área.

3.2 S2 — Mapa de Hotspots

Visualização espacial integrada: heatmap de ocorrências sobreposto ao polígono da área FM, com camadas de câmeras, fatores urbanos e segmentos críticos coloridos por escore. Cada elemento tem legenda e popup.




Figura 4: Seção 2 — Mapa de hotspots.

3.3 S3 — Resumo Executivo

Respostas geradas pela IA para as quatro perguntas operacionais do CompStat: *onde* patrulhar, *quando* patrulhar, *como* empregar a FM e *como* os órgãos devem resolver os fatores urbanos. Cada resposta vem com *provenance* (origem dos dados e nível de confiança).

03
RESUMO EXECUTIVO
Perguntas norteadoras e diagnóstico

Perguntar ao copiloto

PERGUNTA	DIAGNÓSTICO	OPERAÇÃO SUGERIDA
Locais de maior incidência coincidem com a rota da FM?	Análise ainda não gerada Este bloco será preenchido pela IA a partir dos dados da área. Gere quando quiser. Gerar análise	
Horário de maior incidência coincide com o QMD (horário de cobertura)?	Análise ainda não gerada Este bloco será preenchido pela IA a partir dos dados da área. Gere quando quiser. Gerar análise	
A dinâmica criminal coincide com o modelo de emprego da FM?	Análise ainda não gerada Este bloco será preenchido pela IA a partir dos dados da área. Gere quando quiser. Gerar análise	
Os fatores relevantes estão sendo resolvidos pelos órgãos?	Análise ainda não gerada Este bloco será preenchido pela IA a partir dos dados da área. Gere quando quiser. Gerar análise	

Figura 5: Seção 3 — Resumo executivo com proveniência.

3.4 S4 — Ocorrências no Período

Indicadores quantitativos de ocorrências de roubo registradas na área. O período de cobertura está explícito no topo da seção: **janela do piloto de jan/2023 a dez/2024**. Como não há período anterior comparável nos dados disponíveis, a métrica de *variação vs. período anterior* não é exibida (omissão honesta em vez de cálculo inventado).



Figura 6: Seção 4 — Indicadores de ocorrências e período do piloto.

3.5 S5 — Análise Temporal

Mapa de calor 7×24 (dia da semana × hora) que mostra os picos de incidência na área. Acompanha uma síntese textual gerada pela IA, com proveniência.




Figura 7: Seção 5 — Mapa de calor temporal.

3.6 S6 — Dinâmica Criminal

Síntese qualitativa do modus operandi, rotas de fuga e padrões observados, extraída do texto livre de RELINTs e Disque Denúncia. Cada afirmação cita a fonte literal e o nível de confiança — *texto livre é tratado como indício, não como fato*.

06 DINÂMICA CRIMINAL
Perguntar ao copiloto

Como o crime se organiza na área (leitura qualitativa)

Dados insuficientes para esta análise

Não há registros suficientes nesta área e período para a IA sintetizar com segurança. Reúna mais dados ou ajuste o período e gere novamente.

Tentar gerar

Figura 8: Seção 6 — Dinâmica criminal com proveniência.

3.7 S7 — Emprego do Efetivo da FM

Sugestão de cobertura, horário e modalidade (a pé, viatura, moto) para a Força Municipal. A sugestão é uma **recomendação da IA construída a partir de dois insumos**: (i) o *pico temporal* (dia e hora de maior incidência) e (ii) o *deslocamento do autor* — um indício extraído de RELINT e Disque Denúncia, tratado como inteligência, não como fato. A sugestão *não usa* o escore de prioridade da S10. A decisão final é sempre do gestor.

07 EMPREGO DO EFETIVO (FM)
Editar
Perguntar ao copiloto

Sugestões de cobertura, horário e modelo de emprego

CAMPO	SITUAÇÃO ATUAL	SUGESTÃO (IA)	JUSTIFICATIVA
Nº de Agentes por Turno	não informado	—	—
Locais de Cobertura	não informado	—	—
Horário de Cobertura	não informado	—	—
Dias de Cobertura	não informado	—	—
Modalidade de Emprego	não informado	—	—

Como esta sugestão é gerada: é uma recomendação da IA construída a partir de dois insumos — **pico temporal** (dia e horário de maior incidência) e **deslocamento do autor** (indício extraído de RELINT e Disque Denúncia, tratado como inteligência, não como fato). Esta sugestão **não usa o score de prioridade**. A decisão final é sempre do gestor humano.

Sugestões respeitam o teto de 600 agentes para todas as áreas. Dimensionamento final é decisão do comando da FM.

Figura 9: Seção 7 — Sugestão de emprego do efetivo, com explicação dos insumos usados pela IA.

3.8 S8 — Fatores Urbanos

Inventário dos fatores ambientais mapeados na área (iluminação, vegetação, calçada, lixo, mobiliário, situação de rua, trânsito), agregados por tipo e órgão responsável [7, 6].

08 FATORES URBANOS DE INCIDÊNCIA

O que favorece o crime e qual órgão resolve

Perguntar ao copiloto

Pessoas em situação de rua	SMAS	22×
Vegetação encobrindo iluminação pública	COMLURB	13×
Ponto de retenção do tráfego	CET-Rio	11×
Comércio irregular obstruindo a visibilidade do passeio	SEOP	7×
Calçada estreita forçando pedestres à pista	SECONSERVA	5×
Cena de uso de drogas	SMAS	5×
Mobiliário/estrutura servindo de esconderijo	SECONSERVA	4×
Motocicletas trafegando no passeio	GM-Rio	3×
Vegetação obstruindo a visibilidade do passeio	COMLURB	3×
Estacionamento irregular forçando pedestres à pista	SEOP	2×
Mobiliário urbano desviando pedestres para a pista	SECONSERVA	2×
Área mal iluminada com circulação de pedestres	Rio Luz	2×
Veículos de grande porte obstruindo a visibilidade	SEOP	1×
Vãos ou cavidades usados como esconderijo	SECONSERVA	1×

DIAGNÓSTICO IA

... Confiança alta

Figura 10: Seção 8 — Fatores urbanos por tipo e órgão.

3.9 S9 — Câmeras

Cobertura de câmeras CIVITAS/COR na área, com identificação visual de pontos cegos.

09 COBERTURA DE CÂMERAS			Perguntar ao copiloto
Vigilância cadastrada na área (CIVITAS / COR)			
230 CÂMERAS ATIVAS NA ÁREA			
Trechos com crime e sem câmera no raio aparecem como lacuna no painel de coincidências (Seção 10).			
DIAGNÓSTICO IA		... Confiança alta	

Figura 11: Seção 9 — Cobertura de câmeras.

3.10 S10 — Coincidências de Alto Risco e Plano de Ação

Esta é a seção onde o cruzamento das três camadas se materializa em prioridade. Para cada segmento crítico, é calculado um $escore \in [0, 10]$:

$$\text{score} = \min\left(10; 5 \cdot \text{densidade}_{\text{norm}} + 2 \cdot \mathbb{I}[\text{tem fator}] + 1,5 \cdot \mathbb{I}[\text{tem dinâmica}] + 1,5 \cdot \mathbb{I}[\text{lacuna câmera}]\right) \quad (1)$$

Lendo cada termo em linguagem simples:

- $\text{densidade}_{\text{norm}}$ é a densidade de ocorrências do trecho dividida pela densidade máxima da área (varia de 0 a 1). Peso 5: é o sinal mais forte porque é a evidência mais direta de que algo está acontecendo.
- $\mathbb{K}[\text{tem fator}]$ vale 1 se há fator urbano mapeado no raio do trecho, 0 caso contrário. Peso 2: a presença de uma causa removível eleva a prioridade.
- $\mathbb{K}[\text{tem dinâmica}]$ vale 1 se há indício qualitativo (RELINT ou Disque) sobre a área. Peso 1,5: texto livre é indício, peso menor reflete a incerteza.
- $\mathbb{K}[\text{lacuna câmera}]$ vale 1 se não há câmera no raio. Peso 1,5: lacuna de cobertura agrava o segmento.

Os **pesos são uma escolha do produto** (não foram estimados por nenhum modelo) e estão extraídos em constantes nomeadas no código (`app/backend/match/score.py`). A fórmula é exibida na própria tela, no painel da seção S10, para que o gestor não trabalhe com caixa-preta.

10 COINCIDÊNCIAS DE ALTO RISCO E PLANO DE AÇÃO

Onde crime, fator e dinâmica se sobrepõem — e o que fazer

 Editar

 Perguntar ao copiloto

Como o score é calculado: **densidade de crime** (peso 5) + **fator urbano presente** (2) + **dinâmica criminal** (1,5) + **ausência de câmera** (1,5), limitado a 10. Os pesos são uma escolha do produto e podem ser revistos — a decisão final de prioridade é sempre do gestor humano.

548

ÍNDICE DE RISCO DA ÁREA (0–100)

12 segmentos críticos identificados; 10 com fator urbano no entorno; 0 sem cobertura de câmera; dinâmica criminal corroborada por inteligência/denúncia. Segmento de maior prioridade: 8.5 de 10 com 392 roubos.

Mancha criminal Fator urbano Dinâmica criminal

1 **8.50**
SCORE

Concentração de 392 roubos num raio de 150 m; com fatores urbanos no entorno (Calçada estreita forçando pedestres à pista, Cena de uso de drogas, Comércio irregular obstruindo a visibilidade do passeio); corroborada por relato de inteligência/denúncia.

☒ Mancha criminal ☐ Fator urbano ☐ Dinâmica criminal ☐ Lacuna de câmera

OCORRÊNCIAS NO TRECHO CÂMERAS NO RAIOS CONFIANÇA

392

10

*** alta

FATORES PRÓXIMOS

SECONSERVA Calçada estreita forçando pedestres à pista · 30.6 m
CET-Rio Ponto de retenção do tráfego · 45.1 m
SECONSERVA Mobiliário/estrutura servindo de esconderijo · 47.1 m
SEOP Comércio irregular obstruindo a visibilidade do passeio · 57.6 m
SEOP Estacionamento irregular forçando pedestres à pista · 57.6 m
SEOP Veículos de grande porte obstruindo a visibilidade · 57.6 m
SMAS Pessoas em situação de rua · 57.6 m
SMAS Cena de uso de drogas · 57.6 m
COMLURB Vegetação encobrindo iluminação pública · 60.3 m
SMAS Pessoas em situação de rua · 65.2 m
SMAS Pessoas em situação de rua · 67.4 m
SMAS Pessoas em situação de rua · 78.8 m
COMLURB Vegetação encobrindo iluminação pública · 78.8 m
COMLURB Vegetação obstruindo a visibilidade do passeio · 94.4 m
órgão Sem ocorrência · 130.6 m

4 Mapa Preditivo

4.1 O que é e como ler

O Mapa Preditivo é a frente *econométrica* da plataforma. Em vez de um escore aditivo desenhado à mão, aqui um **modelo de regressão logística** estima a probabilidade $\Pr(y_{i,t+s} = 1)$ de *haver pelo menos um roubo* em um micropolígono i na semana $t+s$, com $s \in \{1, 2, 4\}$ semanas à frente.

A unidade espacial é o **hexágono H3 de resolução 9** (aproximadamente $0,1 \text{ km}^2$) dentro do polígono da FM; a unidade temporal é a *semana ISO*. O método dialoga com a literatura de *near-repeat victimization* [4, 2] e *risk terrain modeling* [8].




Figura 13: Mapa Preditivo — visão geral, com seletor de área e painel analítico em três abas (Drivers, Métricas, Coeficientes).

4.2 Especificação econométrica

O modelo é um logit em painel hex-semana, com efeitos fixos de área FM:

$$\Pr(y_{i,t+s} = 1 \mid X_{i,t}) = \Lambda(\alpha_{a(i)} + X_{i,t} \beta_s), \quad s \in \{1, 2, 4\} \quad (2)$$

onde

- i é o hexágono H3 res 9, t a semana, $a(i)$ a área FM do hexágono, $\alpha_{a(i)}$ o efeito fixo de área;
- $\Lambda(z) = e^z / (1 + e^z)$ é a função logística;
- $X_{i,t}$ é o vetor de regressores observados em t , e β_s é o vetor de coeficientes estimado separadamente para cada horizonte s .

O estimador é um logit com regularização L_2 ($C=1,0$, solver `liblinear`) e `class_weight='balanced'` para mitigar desbalanceamento de classes (eventos raros). O split é *temporal*: treino até $T-4$, validação $T-3$ a $T-1$, teste em T — jamais amostragem aleatória, dado o painel.

Grupos de regressores em $X_{i,t}$. Extraídos da Fase 3 do notebook:

1. **Defasagens próprias do crime no hexágono** — y_{lag1} , y_{lag2} , y_{lag4} , y_{lag12} e a soma móvel n_crimes_12w . Capturam o mecanismo de *near-repeat*.
2. **Lag espacial** — W_y_{lag1} , crime na vizinhança ring-1 do hexágono em $t-1$ [4].
3. **Sazonalidade harmônica** — $week_sin$, $week_cos$ (ciclo anual) e $is_holiday_week$ (semanas de feriado nacional/municipal).
4. **Fatores urbanos** — sete componentes ($n_fat_calçada$, n_fat_ilum , n_fat_lixo , n_fat_mobil , n_fat_sitrua , $n_fat_transito$, $n_fat_vegetac$). Justifica-se manter cada componente em vez do total porque eles mapeiam diretamente nos órgãos responsáveis [7, 9].
5. **Cobertura por câmeras** — $n_cameras$ (hex) e $n_cameras_ring1$ (vizinhança).
6. **Sinal qualitativo do Disque** — n_dd_lag1 , contagem de denúncias na semana anterior [6].
7. **Contexto territorial ORCRIM** — $orcrim_CV$, $orcrim_Milícia$, $orcrim_TCP$, com a categoria “*Sem domínio*” omitida como referência (ver caveat abaixo).
8. **Efeitos fixos de área FM** — fe_area_* , com uma área omitida como referência.

4.3 Como interpretar o modelo

A escolha de um logit linear nos regressores não é casual. Modelos mais flexíveis (redes neurais, gradient boosting, random forest) podem oferecer ganhos marginais de precisão, mas *ao custo de uma caixa preta*: o gestor recebe uma probabilidade prevista sem conseguir explicar de onde ela veio. Aqui, a leitura é direta — cada coeficiente β_k tem um significado próprio, em uma fórmula que cabe numa linha. É essa transparência que sustenta o uso responsável da ferramenta na decisão pública.

O que cada coeficiente significa. No logit, o coeficiente β_k é o efeito de um aumento unitário no regressor x_k sobre o *log-odds* de o crime ocorrer. Equivalentemente, $\exp(\beta_k)$ é o *odds ratio* — o fator que multiplica a razão de chances de $y=1$ contra $y=0$ quando x_k aumenta em uma unidade, mantendo todo o resto constante. Em linguagem natural:

- $\exp(\beta_k) > 1$: a variável *aumenta* a chance de crime.
- $\exp(\beta_k) < 1$: a variável *reduz* a chance de crime.
- $\exp(\beta_k) \approx 1$: efeito praticamente neutro.

Exemplo isolado. O coeficiente estimado para y_{lag1} (houve crime no mesmo hex na semana anterior) é $\beta = +0,2346$. O odds ratio é $\exp(0,2346) \approx 1,26$. **Leitura para o gestor:** um hex que teve crime na semana passada enfrenta *cerca de 26% a mais de chance* de ter crime na próxima, comparado a um hex idêntico em todo o resto que não teve. Isto é a evidência quantitativa do mecanismo de *near-repeat* [4, 2] que a literatura já documenta.

Exemplo combinado: somando alavancas no log-odds. Como o preditor linear é uma soma, basta somar os β 's relevantes para compor um cenário. Considere dois hexes hipotéticos, A e B , na mesma área FM (mesmo α), na mesma semana (mesma sazonalidade). A diferença está só nas variáveis abaixo:

Tabela 1: Cenário ilustrativo: hex A “limpo” versus hex B com três alavancas adversas. Coeficientes β extraídos da rodada atual de `coeficientes_logit.csv` ($s=1$).

Variável	β	x_A	x_B	Contribuição em B
y_lag1 (crime semana anterior)	+0,235	0	1	+0,235
w_y_lag1 (crime vizinhança)	+0,366	0	1	+0,366
n_fat_transito ($\times 2$ pontos)	+0,090	0	2	+0,179
n_fat_calcada	+0,054	0	1	+0,054
Diferença no log-odds ($B - A$)				+0,834
Odds ratio $\exp(+0,834)$				$\approx 2,30$

Tradução em risco absoluto. Suponha que A tem uma probabilidade base $P(A) = 10\%$ de crime na próxima semana (próximo da taxa observada no painel). Suas chances de crime são $\text{odds}(A) = 0,10/0,90 \approx 0,111$. Para B , multiplicamos pelo odds ratio: $\text{odds}(B) \approx 0,111 \times 2,30 \approx 0,255$. Convertendo de volta para probabilidade: $P(B) = 0,255/(1 + 0,255) \approx 20\%$. Ou seja, B tem cerca do dobro da probabilidade absoluta de A , mesmo na mesma área e semana.

Como ler coeficientes negativos. O coeficiente de `orcrim_CV` é $\beta = -1,90$, $\exp(-1,90) \approx 0,15$. **Leitura:** hexágonos em território de domínio CV têm, em média no painel, cerca de 85% *menos* chance de roubo registrado em comparação a hexes em “Sem domínio”, controlando por todo o resto. Isto *não significa* que o CV reduz crime: é uma correlação observada, possivelmente por subnotificação ou por efeito inibidor sobre crime patrimonial em territórios sob controle de facções. A leitura correta é “*estar em CV está associado a menos registros*”, nunca “*CV causa menos crime*”.

Coeficientes desprezíveis também informam. O coeficiente de `n_cameras` é $\beta = -0,003$, $\exp(-0,003) \approx 0,997$. **Leitura:** uma câmera adicional no hex está associada a uma redução de cerca de 0,3% nas chances — praticamente nada. Isto não invalida câmeras como política pública (elas geram vídeo para investigação *ex post*), mas mostra que, no painel observado, sua presença não diferencia hexes de alto e baixo risco *ex ante*. O painel de variáveis acionáveis (seção 4.6) já sinaliza esta variável na categoria *Desprezível*.

Resumo prático para o gestor.

1. *Sinal do β :* positivo aumenta risco; negativo reduz.
2. *Magnitude de $\exp(\beta)$:* distância de 1 indica força. Acima de 1,5 é forte; entre 1,05 e 1,5 é moderado; próximo de 1,00 é desprezível.
3. *Efeitos se somam no log-odds e se multiplicam nas odds.* Combinações de fatores adversos podem dobrar ou triplicar a probabilidade rapidamente.
4. *Correlação, não causalidade.* Coeficientes orientam *prioridade*, não garantem que intervir naquela variável reduzirá crime na mesma proporção.

4.4 Métricas de validação

O modelo é avaliado em quatro métricas, computadas sobre o conjunto de teste para cada horizonte de previsão:

- **AUC-ROC** — discriminação ordinal entre hexes que terão e que não terão crime na semana $t+s$.
- **AUC-PR** — precisão-recall, mais sensível ao desbalanceamento de classes (eventos raros).
- **PAI top10 (Prediction Accuracy Index)** — razão entre a fração de eventos capturada nos 10% de hexes de maior risco previsto e a fração de área coberta por esses 10%- **É a principal métrica para policy, na opinião dos autores, porque reflete a eficiência da alocação de recursos: quanto mais eventos capturados em menos área, melhor.** Métrica padrão na literatura de *predictive policing* [1].
- **Moran's I dos resíduos** — autocorrelação espacial residual; valores próximos de zero indicam que o modelo capturou a estrutura espacial do crime.

Resultados atuais (extraídos de `metricas_validacao.csv`):

Tabela 2: Métricas de validação por horizonte de previsão. Conjunto de teste com 156 observações em todos os horizontes; conjunto de treino com 38.220 observações.

Horizonte	AUC-ROC	AUC-PR	PAI top10	Moran's I (p)
$s=1$ (1 sem.)	0,7275	0,3713	3,5294	0,1350 ($p=0,014$)
$s=2$ (2 sem.)	0,7529	0,3871	3,5294	0,1167 ($p=0,017$)
$s=4$ (4 sem.)	0,7088	0,3759	3,5294	0,1434 ($p=0,005$)

Drivers	Métricas	Coeficientes
T+1 SEMANA		
AUC-ROC	AUC-PR	
0.728	0.371	
PAI@10	Moran's I	
3.5	0.135 (p 0.014)	
T+2 SEMANAS		
AUC-ROC	AUC-PR	
0.753	0.387	
PAI@10	Moran's I	
3.5	0.117 (p 0.017)	
T+4 SEMANAS		
AUC-ROC	AUC-PR	
0.709	0.376	
PAI@10	Moran's I	
3.5	0.143 (p 0.005)	
PAI (Predictive Accuracy Index): concentração de acertos no top 10% de hexágonos de maior risco — quanto maior, melhor a priorização operacional.		

Figura 14: Aba “Métricas” do Mapa Preditivo.

4.5 Drivers por área

A aba *Drivers* mostra, para cada área FM, os cinco hexágonos com maior probabilidade prevista e os três fatores que mais contribuem para o risco previsto em cada um (top contribuintes $|\beta \cdot x|$).

Cuidado de leitura. O *rank* ordena os hexágonos *dentro de cada área FM*, não no município inteiro. Isto garante que todas as áreas apareçam representadas; em contrapartida, $P(\text{crime})$ entre áreas diferentes não é diretamente comparável — um *rank 1* em uma área pode ter risco absoluto menor que um *rank 5* em outra. A própria tela exibe esta nota acima da tabela.

Drivers

Métricas

Coeficientes

O **rank** ordena os hexágonos **dentro de cada área da Força Municipal** (top 5 por área), não no município inteiro. Isto garante que todas as áreas apareçam representadas — porém, **P(crime) entre áreas diferentes não é diretamente comparável**: um rank 1 numa área pode ter risco absoluto menor que um rank 5 noutra.

ÁREA	RANK	P(CRIME)	DECIL	DRIVER 1
Bangu: Calçadão - Bangu Shopping	1	54.3%	7	Calçada obstruída 30%
Bangu: Calçadão - Bangu Shopping	2	48.2%	6	Calçada obstruída 50%
Bangu: Calçadão - Bangu Shopping	3	43.3%	5	Crimes acumulados nas últimas
Bangu: Calçadão - Bangu Shopping	4	33.8%	4	Câmeras na vizinhança imediata
Bangu: Calçadão - Bangu Shopping	5	33.1%	4	Crimes acumulados nas últimas
Campo Grande: Estação de	1	39.2%	5	Efeito fixo da área FM 40%

Figura 15: Aba “Drivers” — top hexes por área e seus contribuintes.

4.6 Painel de variáveis acionáveis

Esta é a **contribuição central** do painel preditivo para o gestor. Os regressores do modelo se dividem em duas naturezas:

- **Variáveis estruturais** — defasagens do próprio crime, lag espacial, efeitos fixos de área, sazonalidade, domínio de facção. São úteis para *prever crime*, mas **não orientam intervenção** (o gestor não pode reduzir a sazonalidade nem o passado).
- **Alavancas de política pública** — fatores urbanos desagregados, câmeras, denúncias do Disque. *O município pode agir sobre estas.*

O painel filtra os coeficientes para mostrar *somente* as alavancas, com: direção do efeito ($\uparrow$ aumenta risco / $\downarrow$ reduz / $\approx$ neutro), *magnitude qualitativa* pelo valor absoluto de β (*Notável* $|\beta| > 0,05$; *Leve* $0,01 \leq |\beta| \leq 0,05$; *Desprezível* $|\beta| < 0,01$), órgãos responsáveis e uma nota curta.

Caveat causal. Os coeficientes vêm de um modelo *preditivo*, não de um experimento causal: a correlação observada justifica priorização, não causalidade. Para câmeras, há ainda *viés de seleção* (instalação endógena onde já há crime, o que gera correlação positiva com risco mesmo quando o efeito causal pode ser nulo ou negativo) [10, 11].

Alavancas de política pública					Horizonte: T+1 (1 semana)
Variáveis sobre as quais o município pode agir. Os demais regressores do modelo — defasagens do próprio crime, efeitos fixos de área, sazonalidade e domínio de facção — são úteis para prever crime mas não orientam intervenção.					
VARIÁVEL	CATEGORIA	DIREÇÃO	MAGNITUDE*	ÓRGÃOS RESPONSÁVEIS	NOTA
Trânsito	Fator urbano	$\uparrow$ aumenta risco	Notável	CET-Rio, GM-Rio, SEOP	Pontos de retenção, motos no passeio, estacionamento irregular.
Denúncias do Disque (sem. anterior)	Sinal qualitativo	$\uparrow$ aumenta risco	Notável	Engajamento comunitário	Sinal-ruído baixo; sinais inconsistentes entre horizontes.
Calçada	Fator urbano	$\uparrow$ aumenta risco	Notável	Seconserva, SEOP	Calçada estreita ou obstruída empurrando pedestre para a via.
Lixo / limpeza	Fator urbano	$\uparrow$ aumenta risco	Leve	Comlurb	Entulho ou lixo acumulado obstruindo visibilidade.
Iluminação	Fator urbano	$\uparrow$ aumenta risco	Desprezível	RioLuz	Trecho mal iluminado.
Câmeras na vizinhança	Cobertura	$\uparrow$ aumenta risco	Desprezível	CIVITAS, COR	Cuidado: mesma ressalva de endogeneidade.
Vegetação	Fator urbano	$\uparrow$ aumenta risco	Desprezível	Comlurb	Vegetação encobrindo iluminação ou visibilidade.
Mobiliário urbano	Fator urbano	$\downarrow$ reduz risco	Desprezível	Seconserva	Mobiliário abandonado servindo como esconderijo.
Câmeras no trecho	Cobertura	$\approx$ neutro	Desprezível	CIVITAS, COR	Cuidado: instalação endógena (câmeras vão onde há crime).
Situação de rua	Fator urbano	$\approx$ neutro	Desprezível	SMAS	População em situação de rua mapeada.

* Categorias de magnitude pelo valor absoluto do coeficiente β : **Notável** $|\beta| > 0,05$; **Leve** $0,01 \leq |\beta| \leq 0,05$; **Desprezível** $|\beta| < 0,01$.

Os coeficientes vêm de um modelo preditivo, não de um experimento causal: a correlação observada justifica priorização, não causalidade. Para câmeras, há ainda viés de seleção (instalação onde já há crime).

Figura 16: Painel de variáveis acionáveis. As alavancas estão ordenadas por $|\beta_{s=1}|$ decrescente.

4.7 Mapa interativo e popups por hexágono

O mapa interativo serve as predições T+1 por padrão, com toggles para T+2 e T+4 e overlay dos polígonos FM. Cada hexágono, ao ser clicado, abre um popup com: área(s) FM, horizonte, P(crime), decil de risco e os três fatores que mais explicam aquele risco.




Figura 17: Mapa interativo — horizonte T+1.




Figura 18: Mapa preditivo filtrado por área (Presidente Vargas — Campo de Santana — Central do Brasil — Cinelândia), mostrando o recorte de hexágonos dentro do polígono da Força Municipal.




Figura 19: Popup detalhado de um hexágono, com os três principais drivers.

4.8 Coeficientes em português

A aba *Coeficientes* mostra todos os regressores estimados com seus *odds ratios* por horizonte ($\exp(\beta)$). Para reduzir fricção de leitura, os nomes técnicos das variáveis são traduzidos para rótulos em português natural (p. ex. y_{lag1} → “Crime no mesmo trecho (1 semana antes)”; n_{fat_ilum} → “Fator urbano: iluminação”). O nome técnico continua sendo a chave canônica nos CSVs.

Drivers	Métricas	Coeficientes
Odds ratio > 1 aumenta a chance de crime; < 1 reduz. Por horizonte de previsão.		
FEATURE	OR T+1	
Domínio: Milícia	1.89	
Domínio: Comando Vermelho	0.15	
Área FM: Campo Grande: Estação de Trem - Calçadão	0.29	
Área FM: Presidente Vargas - Campo de Santana - Central do Brasil - Cinelândia	1.49	
Crime na vizinhança imediata (1 semana antes)	1.44	
Domínio: Terceiro Comando Puro (TCP)	0.65	
Área FM: Rodoviária - Terminal Gentileza - Estação Leopoldina	0.69	
Crime no mesmo trecho (1 semana antes)	1.26	
Área FM: Estações São Francisco Xavier - Afonso Pena	1.23	
Área FM: Praia de Botafogo - Rua Marquês de Abrantes	0.77	
Área FM: Jardim de Alah	0.78	
Crime no mesmo trecho (2 semanas antes)	1.20	
Crime no mesmo trecho (4 semanas antes)	1.20	
Área FM: Metrô Botafogo - Rua São Clemente - Rua Voluntários da Pátria	0.87	
Total de crimes nas 12 semanas anteriores	1.10	
Fator urbano: trânsito	1.09	

Figura 20: Aba “Coeficientes” com rótulos em português.

5 Guardrails de IA responsável

Este é um projeto de segurança pública. As regras abaixo são *inegociáveis* e aparecem em todas as superfícies da aplicação.

1. **Decisão final sempre humana.** A plataforma produz *rascunhos* auditáveis (relatório, sugestões, escores). O Relatório exportado em DOCX vem marcado com banner “*RASCUNHO — validação humana*”.
2. **Foco no ambiente, não no indivíduo.** A plataforma analisa fatores urbanos e alocação de patrulha, não vigia pessoas [5, 7].
3. **Texto livre é indício, não fato.** Disque Denúncia e RELINTs sempre vêm com citação literal, fonte rastreável e nível de confiança. A IA sinaliza incerteza em vez de afirmar.
4. **Nunca inventar dado.** Camada ausente é declarada como ausente. Escore com dado insuficiente é marcado como *baixa confiança*.
5. **Cuidado com o viés de realimentação.** Priorizar sempre as mesmas áreas gera mais patrulha, mais registro e escore artificialmente mais alto na próxima iteração. A literatura documenta este risco em modelos preditivos de policiamento [10, 11]; a plataforma deve ser usada com revisão humana periódica.
6. **LGPD.** Dados são tratados como agregados territoriais. Dados pessoais (Disque, CPSR) são minimizados. O copiloto não tem acesso a SQL livre — apenas a uma *whitelist* de consultas.
7. **Transparência da fórmula.** O escore da S10 é uma soma ponderada com pesos extraídos em constantes nomeadas; a fórmula é exibida na própria tela. Não há caixa-preta.

Referências

- [1] Chainey, S., Tompson, L., & Uhlig, S. (2008). The Utility of Hotspot Mapping for Predicting Spatial Patterns of Crime. *Security Journal*, 21(1–2), 4–28.
- [2] Mohler, G. O., Short, M. B., Brantingham, P. J., Schoenberg, F. P., & Tita, G. E. (2011). Self-Exciting Point Process Modeling of Crime. *Journal of the American Statistical Association*, 106(493), 100–108.
- [3] Mohler, G. O., Short, M. B., Malinowski, S., Johnson, M., Tita, G. E., Bertozzi, A. L., & Brantingham, P. J. (2015). Randomized Controlled Field Trials of Predictive Policing. *Journal of the American Statistical Association*, 110(512), 1399–1411.
- [4] Johnson, S. D., & Bowers, K. J. (2004). The Burglary as Clue to the Future: The Beginnings of Prospective Hot-Spotting. *European Journal of Criminology*, 1(2), 237–255.
- [5] Cohen, L. E., & Felson, M. (1979). Social Change and Crime Rate Trends: A Routine Activity Approach. *American Sociological Review*, 44(4), 588–608.
- [6] Wheeler, A. P. (2018). The Effect of 311 Calls for Service on Crime in Washington, DC, at Microplaces. *Crime & Delinquency*, 64(14), 1882–1903.
- [7] O’Brien, D. T., & Sampson, R. J. (2015). Public and Private Spheres of Neighborhood Disorder: Assessing Pathways to Violence Using Large-Scale Digital Records. *Journal of Research in Crime and Delinquency*, 52(4), 486–510.

- [8] Caplan, J. M., Kennedy, L. W., & Miller, J. (2011). Risk Terrain Modeling: Brokering Criminological Theory and GIS Methods for Crime Forecasting. *Justice Quarterly*, 28(2), 360–381.
- [9] Chalfin, A., Hansen, B., Lerner, J., & Parker, L. (2019). Reducing Crime through Environmental Design: Evidence from a Randomized Experiment of Street Lighting in New York City. *NBER Working Paper* No. 25798.
- [10] Lum, K., & Isaac, W. (2016). To Predict and Serve? *Significance*, 13(5), 14–19.
- [11] Ensign, D., Friedler, S. A., Neville, S., Scheidegger, C., & Venkatasubramanian, S. (2018). Runaway Feedback Loops in Predictive Policing. *Proceedings of Machine Learning Research (FAT*)*, 81, 160–171.